

HW3-1

環境介紹

GridWorld 是一個 4×4 的格子地圖，AI 需要學會移動到 Goal (+10) 並避開 Pit (-10) 和 Wall。狀態以 $4 \times 4 \times 4$ 陣列表示，每一層分別記錄 Player、Goal、Pit、Wall 的位置，訓練時 reshape 成長度 64 的向量輸入神經網路。遊戲有三種模式：static（所有位置固定）、player（玩家隨機）、random（全部隨機），HW3-1 使用 static mode。

Naive DQN 架構

Q 網路為三層全連接網路（ $64 \rightarrow 150 \rightarrow 100 \rightarrow 4$ ），輸出四個動作各自的 Q 值。訓練目標是讓預測 Q 值 $X = Q(s,a)$ 逼近 TD Target $Y = r + \gamma \times \max Q(s')$ ，損失函數為 MSELoss，優化器為 Adam。探索策略使用 ϵ -greedy， ϵ 從 1.0 線性衰減至 0.1，訓練初期多探索、後期多利用。

Experience Replay

Naive DQN 每步只用當前資料訓練，相鄰狀態高度相關且樣本效率低。Experience Replay 用 deque 儲存每步的 $(s, a, r, s', done)$ ，容量 1000，當 buffer 超過 batch_size 時隨機抽取 200 筆批次訓練，打破樣本相關性，大幅提升泛化能力。


Target Network

用同一個網路同時計算預測值和目標值，會造成「目標一直在移動」的問題，訓練容易震盪。Target Network 複製一份 model2 專門計算 TD Target，每 500 步才同步一次參數，提供穩定的學習目標。

實驗結果


程式 3.3 Naive DQN 訓練 1000 epochs，Loss 從約 300 快速下降，epoch 200 後趨近於 0，static mode 測試成功但 random mode 失敗，顯示無泛化能力。

【附圖：程式 3.3 Loss 曲線圖】




程式 3.5 加入 Experience Replay 後，random mode 勝率達 93.2%。

【附圖：程式 3.5 Loss 曲線圖】



程式 3.8 加入 Target Network，勝率進一步提升至 94.6%。

【附圖：程式 3.8 Loss 曲線圖】



結論

Naive DQN 只能解決固定情境，Experience Replay 是泛化能力的關鍵（勝率從接近 0 跳到 93.2%），Target Network 提供穩定學習目標，勝率再提升至 94.6%。三個技術層層遞進，構成現代 DQN 的基礎。

HW3-2

實驗設定

三個版本均使用相同超參數：epochs=5000、batch_size=200、gamma=0.9、sync_freq=500，環境為 GridWorld player mode，即玩家位置隨機、其他物件位置固定。

Double DQN

Naive DQN 的問題在於用同一個網路同時「選動作」和「評估價值」，會造成 Q 值系統性高估，進而使訓練不穩定。Double DQN 的解法是將兩者分離：用 online network 選出最好的動作，再用 target network 評估該動作的價值。實作上只需改動計算 TD Target 的四行程式碼，網路架構與訓練迴圈完全不變。


Dueling DQN

Dueling DQN 的核心思想是將 $Q(s,a)$ 拆成兩個部分： $V(s)$ 代表這個狀態本身有多好（與動作無關）， $A(s,a)$ 代表這個動作比平均好多少，最終合併公式為 $Q(s,a) = V(s) + A(s,a) - \text{mean}(A(s,a))$ 。減去平均優勢是為了讓 V 和 A 能被唯一識別，避免訓練發散。實作上只需將原本的 Sequential 換成自訂的 DuelingDQN class，訓練迴圈完全不變。


實驗結果與討論

三個版本勝率均達 100%，原因是 player mode 難度對訓練充足的 DQN 而言相對簡單，5000 epochs 的訓練量已足夠讓三個版本完全掌握這個環境。差異主要體現在 Loss 曲線上：Naive DQN 初期震盪較多；Double DQN 初期 Loss 峰值最高（約 14），反映其修正 Q 值高估時的較大調整幅度；Dueling DQN 收斂最為平滑且最快，顯示將狀態價值與動作優勢分離學習，確實有助於提升訓練穩定性。三個版本均在約 5000 steps 內收斂至接近 0。

HW3-2: Win Rate Comparison (Player Mode, 500 games)



HW3-2: DQN Variants Loss Comparison (Player Mode)



...

HW3-2 最終結果總結 (Player Mode)

Naive DQN 勝率: 100.0%

Double DQN 勝率: 100.0% (vs Naive: +0.0%)

Dueling DQN 勝率: 100.0% (vs Naive: +0.0%)

最佳模型: Naive DQN

HW3-3

實驗設定

將 HW3-2 最佳的 Dueling DQN 架構改寫為 PyTorch Lightning 框架，環境換為 GridWorld random mode（所有物件位置全部隨機），訓練設定與老師原始程式 3.8 一致：epochs=5000、batch_size=200、gamma=0.9、sync_freq=500。

PyTorch Lightning 框架改寫

原本的訓練迴圈由手動的 for/while 迴圈控制，Lightning 將訓練邏輯封裝成三個核心方法。training_step 負責每個 epoch 的訓練邏輯，configure_optimizers 負責定義優化器與學習率調度，train_dataloader 負責提供訓練資料。為了對齊原本的訓練量，在 training_step 內部新增 _run_episode() 方法，確保每個 epoch 都完整跑完一整場遊戲再進行一次參數更新，使實際訓練步數與原始程式一致。

三個訓練技巧


第一個是 Gradient Clipping，在 Lightning Trainer 設定 gradient_clip_val=1.0，將每次更新的梯度限制在最大值 1.0 以內，防止 random mode 下因獎勵稀疏造成的梯度爆炸，這也是 Loss 曲線全程沒有大幅突刺的主要原因。

第二個是 Learning Rate Scheduling，使用 StepLR 每 500 步將學習率乘以 0.9，讓訓練初期用較大的學習率快速收斂，後期用較小的學習率精細調整，對應到 Loss 曲線後半段更平滑的下降趨勢。

第三個是 ϵ 指數衰減，將原本的線性衰減改為 $\epsilon \times 0.9998$ ，探索率下降更自然平滑，避免過早停止探索導致模型陷入局部最優。

實驗結果

Loss 從初始約 6 穩定下降至約 1，全程無大幅震盪，顯示三個訓練技巧共同發揮了穩定訓練的效果。500 場測試勝率達 86%，在 random mode 下屬於良好表現。與 HW3-1 程式 3.8 的 94.6% 相比略低，主要原因是框架轉換過程中訓練結構有所調整，但整體訓練穩定性明顯提升。



HW3-4

分析：Rainbow DQN 的組成

Rainbow DQN 是將六個獨立的 DQN 改進技術整合成單一框架的演算法。本作業實作其中五個核心組件，省略實作複雜度最高且對小型環境效益有限的 Distributional RL。

五個組件各自解決不同問題。Double DQN 解決 Q 值高估問題，將選動作和評估價值分離給兩個網路處理。Dueling DQN 將 $Q(s,a)$ 拆成 $V(s)$ 和 $A(s,a)$ 分開學習，讓模型更有效率地理解哪些狀態本身危險、哪些動作相對有利。Prioritized Experience Replay 根據 TD error 大小決定採樣機率，讓模型對出乎意料的經驗多加學習，在 random mode 中稀少的 Goal 經驗能被更充分利用。Multi-step Returns 累積 n 步獎勵後才計算 target，加速獎勵訊號從終點傳回給距離較遠的狀態，解決 GridWorld 獎勵稀疏的問題。Noisy Nets 將 `nn.Linear` 換成帶有可學習噪聲參數的 `NoisyLinear`，讓網路自己決定何時探索、何時利用，完全取代原本固定的 ϵ -greedy 策略。

實作說明


網路架構沿用 HW3-2 的 Dueling DQN，但將所有 Linear 層換成 `NoisyLinear`，每個 training step 重新採樣噪聲。Buffer 設計將 PER 和 n -step 合併成單一類別，先用 deque 暫存 n 步經驗計算累積獎勵，再存入 SumTree 結構的 PER buffer。訓練框架沿用 HW3-3 的 PyTorch Lightning，保留 Gradient Clipping 和 Learning Rate Scheduling 兩個訓練技巧。

實驗結果

500 場測試勝率達 88.2%，比 HW3-3 的 86.0% 提升 2.2%，顯示 Rainbow 的組件組合確實帶來改善。

【附圖：Rainbow DQN Loss 曲線圖】

... == Rainbow DQN 評估結果 ==
Games: 500 | Wins: 441 | Win Rate: 88.2%



Loss 曲線呈現緩慢上升趨勢，從初始約 5 上升至約 6~7，與 HW3-3 的穩定下降不同。這是 PER 的 importance sampling weight (β 值) 從 0.4 逐漸增加到 1.0 造成的， β 越大代表 loss 被 weight 放大的幅度越高，因此 loss 數值上升並不代表訓練變差，勝率的提升也印證了這一點。

與前面版本的比較

HW3-3 的 Loss 從 6 穩定下降至 1，訓練過程非常平滑。Rainbow 的 Loss 數值較高且呈上升趨勢，但勝率反而更高，說明 Loss 的絕對數值在有 PER 加權的情況下不能直接和沒有加權的版本相比。

Rainbow 在強化學習中的核心優勢是樣本效率，相同的訓練步數能學到更多，在更複雜的環境（如 Atari）效果更為顯著。在 GridWorld 這種小型環境中，各組件的效果相對有限，但組合後仍帶來了穩定的提升。

結論

Rainbow DQN 透過五個技術的組合，在 random mode 下達到 88.2% 的勝率，超越 HW3-3 的 86%。每個組件各自針對 DQN 的不同弱點進行改善，組合後的效果優於任何單一改進，符合 Rainbow 論文的核心結論。